

NPP-GUARD

从分类器到可审计的 核电事故诊断原型

NPPAD 仿真时序数据 · 01-19 研究路线 · v1 release protocol

会拒答 · 可解释 · 可复现

科研汇报 / 创新竞赛 / 面试展示

2026-09-22

问题与场景

事故诊断的难点首先是证据边界，而不是模型数量。

早期窗口

30/60 s 可能没有足够可
辨识信息

标签与耦合

严重度与过程变量可能
高度耦合

评估泄漏

随机拆分时间行会共享
同一条轨迹

分布偏移

severity extrapolation
会改变任务难度

项目目标

在证据不足时明确输出 Unknown / Requires Review，并把数据质量、模型依据和限制一起交付。

NPPAD 数据与评估挑战


固定输入边界，让模型只能使用明确声明的过程信号。



数据审计结论


独立 Normal reference 不足 · 事故前仅有 t=0 · singleton 类别延后 · 时间行不随机拆分

研究路线：从负结果到 release protocol




方法学转折：不把 random split 的高分直接当作外部泛化

LOCA 专项：严重度可估计，保护时间仍有限



07 · Ridge + 120 s

MAE 0.4492 percentage points · R^2 0.9996




08 · 60 s + Random Forest

MAE 86.826 s · R^2 0.3303


多事故诊断：120 s 才出现可见区分度

A strict 38 · test




Macro-F1

30/60 s 相同结果触发了特征、采样点、cohort 与预测分布审计；120 s 只作为探索窗口，不是早期预警保证。



OOD 验证: severity extrapolation 会拉低结果



120 s · A strict 38

random 0.6573


severity-blocked 0.5931

extrapolation 0.4826

结论

跨严重度压力测试仍不足以支持直接进入深度学习或部署泛化声明。

Selective diagnosis: 拒答本身也是输出



16 · alpha = 0.10

经验 set coverage

68.9%

Selective Macro-F1


0.6700

Distance OOD proxy AUROC

0.8221

经验覆盖率不等于统计保证；v1 保留
Unknown / Requires Review。


NPP-Guard v1 架构



17.2 release protocol: 先隔离, 再比较

locked release test = 101 条轨迹

release test 与所有 fit / calibration 集 zero overlap




API / batch exact parity


101/101 = 100%

最大浮点绝对差 0 · regression 18/18 · SHA-256 10/10

Explainability: 解释模型如何判断，不伪装成因果



Top variables: P / WSTA / TAVG / WFWA / LSGA



Top-5 Jaccard 0.9722 · family faithfulness +0.7532

18 gate: artifact SHA-256 10/10 · parity 101/101 · regression 18/18

Dashboard: 把诊断、拒答和解释放进同一页面

真实样例路径

FLB/10.csv · LOCAC/19.csv · LOCAC/12.csv · LR/93.csv · 50 s truncation

accepted

研究模型接受

requires_review

OOD / 能力边界

unknown

证据不足

invalid_input

预测前拒绝

5/5 smoke · 3/3 helper · HTTP 200 · AppTest 0 exceptions · JSON export excludes raw CSV

本次交付未生成虚构截图；演示使用仓库中的真实样例路径。

关键实验总表：数字必须连同协议一起看

阶段	协议 / 窗口	指标	记录
07	grouped · 120 s	LOCA MAE	0.4492 pp
08	strict · 60 s	Protection MAE	86.826 s
10	random · 30/60/120 s	Macro-F1	0.1928 / 0.1928 / 0.7526
13	blocked / extrapolation · 120 s	Macro-F1	0.5931 / 0.4826
16	extrapolation · alpha .10	Coverage / F1	68.9% / 0.6700
17.2	locked · 101	Parity / regression	101/101 / 18/18
19	Streamlit local	Dashboard tests	5/5 / 3/3 / HTTP 200

协议差异、支持度与限制见 docs/NPP-Guard_Key_Results_Table.md

方法学贡献与项目化交付

方法学

- 1 完整 trajectory/sample_id 分组
- 2 train-only preprocessing + leakage flags
- 3 random / blocked / extrapolation 分开报告

交付形态

- 1 conformal + distance 的主动拒答
- 2 冻结 artifact + exact parity
- 3 解释层与 Streamlit Dashboard

重点不是把系统包装成“99% 分类器”，而是让每个结论带着协议、证据和边界。

局限性与下一步

当前能交付的，是一个可审计的研究原型。

- Normal reference 不足，early-warning 仍不充分
- severity extrapolation 性能下降，部分类支持度低
- conformal 经验 coverage 不是统计保证
- subtype OOD 与 protection-time 链式输入未解决

下一步

固定功率 Normal
跨工况外部测试
更多 severity 覆盖
更严格 uncertainty
calibration

在这些边界补齐前，不把 NPP-Guard 表述为真实核电站安全系统。